

大作业实验报告

姓名：史铠瑞 学号：2025010531

一、数据来源与数据量

数据来源

数据来自网易云音乐的官方 API(三个接口)+歌曲详情页 HTML 解析。歌曲列表（歌手列表页为 JS 渲染，无法直接抓 HTML）、歌手信息、歌词走 API；歌曲名/歌手名/专辑/封面通过抓取歌曲详情页 HTML、正则解析信息获得。

爬虫预先准备了一个 100 位歌手的 singer_ids 列表，这里是我自己手动去网易云音乐找到的，为了保证歌手至少有 25 首歌曲并且大部分有歌词,从而满足题目要求:)对于程序本身的可扩展性有一些削弱，但是可以后续调整。

数据量

数据项	数量
爬取的歌手	100 位
爬取的歌曲	2500 首（每位歌手 25 首）
有歌词的歌曲	2447 首
数据库 music_artist 表	100 条
数据库 music_song 表	2500 条
数据库 music_comment 表	0 条（没写，截止到提交）
本地图片	歌手头像 100 张+歌曲封面

约 2500 张

二、主要功能

爬虫

功能

说明

抓取歌手信息

名字、头像、简介、个人主页链接

抓取歌曲列表

每位歌手 25 首热门歌曲

抓取歌词

自动清洗掉[00:12.34]这类时间标签

下载图片

歌手头像、歌曲封面，下载前检查是否已存在（去重）

容错处理

每步都 try/except，失败不中断，返回默认值

反爬策略

每首歌之间随机延时 3~6 秒，每位歌手之间随机 10~15 秒

增量保存

每爬完一位歌手就 save_data()保存下，防止中途崩溃丢失前面的数据

网站

网站共提供 7 个 URL:

URL

功能

	歌曲列表（主页，分页显示，
/	每页 10 首，设计成 10 首是为了
	方便验收查歌曲数量)
/song/<id>/	歌曲详情（封面、歌手、歌
	词、原始链接、评论区)
/song/<id>/comment/	发表评论
/comment/<id>/delete/	删除评论
/artist/	歌手列表（分页）
/artist/<id>/	歌手详情（头像、简介、全
	部歌曲)
/search/	搜索

具体功能点：

列表分页：歌曲/歌手列表用 Paginator 分页，每页 10 条，支持首页/上一页/下一页/尾页/页码跳转

歌曲详情：展示封面大图、歌手（可点击跳转至网易云原网站）、歌词原文；

评论功能：可发表评论、删除评论，输入框带实时字数统计；

搜索功能：输入关键词，在歌曲名/歌手名/歌词里做字符串匹配，结果显示命中条数和查询耗时（秒）；

数据分析


对清洗后的 1513 首华语歌做三个结论：

1.歌词高频词：用 jieba 分词+Counter 统计，得出华语流行乐的高

频词：

【结论一】歌词高频词 Top 20

1.	的	22354	次	占比	6.00%
2.	我	17343	次	占比	4.65%
3.	你	16022	次	占比	4.30%
4.	在	5756	次	占比	1.54%
5.	了	4561	次	占比	1.22%
6.	是	4331	次	占比	1.16%
7.	爱	2926	次	占比	0.78%
8.	不	2878	次	占比	0.77%
9.	都	2551	次	占比	0.68%
10.	有	2210	次	占比	0.59%
11.	着	2195	次	占比	0.59%
12.	就	2185	次	占比	0.59%
13.	也	2031	次	占比	0.54%
14.	让	1920	次	占比	0.51%
15.	我们	1750	次	占比	0.47%
16.	说	1733	次	占比	0.46%
17.	人	1624	次	占比	0.44%
18.	这	1538	次	占比	0.41%
19.	会	1534	次	占比	0.41%
20.	谁	1527	次	占比	0.41%




除了的，我，你，在这些没有实际意义的词，我们发现“爱”是这一千余首歌曲里面的出现最高的词汇，占比接近百分之一。我们得出结论，在华语乐坛（至少是选中的这些歌）中主要是情歌。

2.歌词长度分布：用 numpy 直方图分箱，发现大多数歌词集中在 200~500 字；


【结论二】歌词长度分布

最短 60 字，最长 1834 字，平均 394 字，中位数 375 字

0~100	字：	4	首	(0.3%)
100~200	字：	61	首	(4.0%)
200~300	字：	257	首	(17.0%)
300~400	字：	561	首	(37.1%)
400~500	字：	385	首	(25.4%)
500~600	字：	138	首	(9.1%)
600~800	字：	89	首	(5.9%)
800~1000	字：	11	首	(0.7%)
1000~2000	字：	7	首	(0.5%)



3.说唱 vs 情歌：对比马思唯与三组共 18 位情歌歌手，说唱歌词约为情歌的 1.8 倍。



三、使用的技术与算法

爬虫技术

1.HTTP 请求：用 requests 库发送 GET 请求，并伪造 User-Agent、Referer 请求头，模拟浏览器访问；

2.正则表达式匹配：

清洗歌词时间标签: `re.sub(r'\[.*?\]', '', raw)`, 非贪婪匹配, 把 `[00:12.34]` 全部去掉;

清洗非法文件名: `re.sub(r'\\\/:*\?"<>|]','_', name)`, 把 Windows 不允许的字符替换成下划线 (这里是调试过程中爬虫崩掉了才发现的 bug 并且做了后续处理) ;

3.反爬延时: `time.sleep(random.uniform(3,6))` 随机延时, 防止被拦截;

4.容错机制: 所有网络请求都用 `try/except` 包裹, 单个请求失败不影响整体爬取 (这里也有一个极为惨重的 bug, 当时爬了一个多小时发现中途断网了: (感觉世界毁灭了) ;

网站技术

1.外键关联: Song 通过 ForeignKey 关联 Artist, Comment 关联 Song, 这样一是为了表明附属关系, 二是为了匹配定位, 方便 artist 和 song 彼此查找;

2. Q 对象实现多字段字符串搜索;

3.分页 Paginator;

4.模板继承: `base.html` 定义公共布局和 CSS, 各页面用 `{%block%}` 替换内容;

统计算法

1.中文分词: jieba 把歌词切成词;

2.词频统计: `collections.Counter` 累加计+`most_common()`排序;

3.数据清洗算法: 按「汉字占比」过滤华语歌曲, 正则过滤歌词里的「作词/作曲」等制作信息头;

4.分箱统计: `numpy.histogram()`按字数区间统计歌曲数量;

5.分组均值对比: 把歌手分组, 各自计算歌词字数的平均值, 用柱状图对比。